

MEMORIA JUSTIFICATIVA PARA LA ACEPTACIÓN DEL ANTEPROYECTO

Título: “Clasificación Automática de Residuos Reciclables mediante Deep Learning:
Análisis Comparativo de Arquitecturas CNN Modernas para Sistemas SDDR”

Autor: [PABLO HUIDOBRO GARCÍA]

UNIVERSIDAD: [FRANCISCO DE VITORIA]

FECHA DE ENTREGA 15/12/2025

Índice

1. MOTIVACIÓN	5
2. OBJETIVOS	5
2.1 Objetivo Principal.....	5
2.2 Objetivos Secundarios.....	5
3. JUSTIFICACIÓN DEL PROYECTO	6
4. ESTADO DEL ARTE	6
5. METODOLOGÍA	13
5.1 Diseño del Dataset.....	13
5.2 Data Augmentation	14
5.3 Arquitecturas de Redes Neuronales	14
5.3.1 Criterios de Selección.....	14
5.3.2 Implementación	16
5.4 Transfer Learning e Implementación	16
5.5 Protocolo de Entrenamiento	17
5.6 Evaluación Comparativa.....	17
6. PLANIFICACIÓN	18
6.1 Cronograma (12 semanas).....	18
6.2 Recursos Necesarios	19
7. EVALUACIÓN Y MÉTRICAS	19
7.1 Métricas Cuantitativas.....	19
7.2 Análisis Cualitativo.....	20
7.3 Métricas de Eficiencia	20
7.4 Criterio de Decisión	20
8. RESULTADOS ESPERADOS	20
9. ORIGINALIDAD Y APORTACIÓN.....	21

10. LIMITACIONES Y RIESGOS 22

10.1 Identificación de Limitaciones 22

10.2 Estrategias de Mitigación 23

11. CONSIDERACIONES ÉTICAS Y SOSTENIBILIDAD..... 23

11.1 Contribución a la Sostenibilidad..... 23

11.2 Privacidad y Consideraciones Legales..... 24

11.3 Consideraciones de Equidad 24

12. REFERENCIAS..... 25

RESUMEN EJECUTIVO

Este anteproyecto propone el desarrollo de un sistema de clasificación automática de residuos reciclables (botellas PET, botellas de vidrio, latas de aluminio) mediante redes neuronales convolucionales, con objetivo de alcanzar $>90\%$ de F1-Score en condiciones operativas reales. La investigación aborda la brecha existente entre precisión en entornos controlados y deployment en sistemas SDDR operativos mediante: (1) creación de un dataset original de 900-1500 imágenes capturadas en condiciones deliberadamente heterogéneas que replican variabilidad real de iluminación, fondos y estados de conservación; (2) comparativa rigurosa de tres arquitecturas CNN modernas (ResNet50, EfficientNet-B3, ConvNeXt-Tiny) mediante transfer learning, incluyendo evaluación de arquitecturas recientes no exploradas suficientemente en este dominio; y (3) evaluación multicriterio considerando precisión, eficiencia computacional y viabilidad de deployment en hardware embebido. En el contexto regulatorio actual, donde España debe implementar sistemas SDDR antes de noviembre de 2026 según la Ley 7/2022 de Economía Circular, este proyecto proporciona evidencia empírica directamente aplicable. El proyecto contribuirá con un dataset etiquetado público de condiciones operativas heterogéneas, análisis empírico de arquitecturas modernas en este dominio específico, y metodología reproducible para futuras investigaciones en clasificación automática de residuos.

1. MOTIVACIÓN

La gestión inadecuada de residuos constituye uno de los principales desafíos ambientales del siglo XXI. Según datos de la Comisión Europea, solo el 47% de los envases de plástico se reciclan en España, mientras que la tasa de reciclaje de vidrio alcanza el 76% y la de aluminio el 88%. Esta disparidad evidencia la necesidad de optimizar los procesos de clasificación en origen, especialmente en sistemas de devolución, depósito y retorno (SDDR).

Los sistemas SDDR tradicionales requieren intervención manual o sistemas mecánicos costosos para la clasificación de residuos. La automatización mediante visión artificial puede incrementar la eficiencia de estos sistemas hasta en un 40%, reducir costes operativos y minimizar la contaminación cruzada entre materiales reciclables. Además, la implementación de tecnologías inteligentes en puntos de reciclaje puede aumentar la participación ciudadana al ofrecer procesos más ágiles y precisos.

El desarrollo de modelos de clasificación basados en deep learning ha demostrado resultados prometedores en entornos controlados, pero existe una brecha significativa en su aplicación a condiciones reales con variabilidad de iluminación, fondos diversos y estados de conservación heterogéneos de los envases. Este proyecto busca contribuir a cerrar esta brecha mediante la creación de un dataset realista y la evaluación sistemática de arquitecturas CNN modernas.

2. OBJETIVOS

2.1 Objetivo Principal

Evaluar la viabilidad de redes neuronales convolucionales modernas para la clasificación automática de residuos reciclables en condiciones operativas representativas de sistemas de devolución, depósito y retorno (SDDR).

2.2 Objetivos Secundarios

1. Validar la capacidad de generalización de arquitecturas CNN modernas mediante transfer learning en condiciones heterogéneas que repliquen la variabilidad inherente a entornos SDDR operativos (variaciones de iluminación, fondos diversos, estados de conservación heterogéneos).
2. Determinar qué arquitectura CNN (ResNet50, EfficientNet-B3, ConvNeXt-Tiny) ofrece el mejor equilibrio entre precisión de clasificación y eficiencia computacional para aplicaciones de reciclaje automático en tiempo real.

3. Cuantificar el impacto de transfer learning y data augmentation estratégico en la robustez de modelos de clasificación de residuos entrenados con datasets de tamaño limitado (900-1500 imágenes).
4. Contribuir al conocimiento del dominio mediante la generación de un dataset etiquetado público capturado en condiciones deliberadamente heterogéneas y el desarrollo de una metodología reproducible para futuras investigaciones en clasificación automática de residuos.

3. JUSTIFICACIÓN DEL PROYECTO

La Unión Europea ha establecido como meta para 2030 que el 90% de las botellas de plástico sean recolectadas para reciclaje, lo que incrementa la presión sobre los Estados miembros para implementar sistemas SDDR eficientes. España se encuentra actualmente evaluando la adopción masiva de estos sistemas, lo que representa una oportunidad para integrar tecnologías de clasificación inteligente desde el diseño inicial.

Las investigaciones previas en clasificación automática de residuos se han centrado mayoritariamente en datasets sintéticos o en condiciones de laboratorio altamente controladas, limitando su aplicabilidad directa a entornos operativos. Existe una brecha significativa entre el rendimiento reportado en literatura académica (frecuentemente superior al 95% en condiciones ideales) y el desempeño real en sistemas desplegados, donde la precisión puede descender hasta el 75-80%.

Este proyecto aborda específicamente esta brecha al: (1) crear un dataset que refleje condiciones reales de uso incluyendo variabilidad de iluminación, fondos no uniformes, estados de conservación diversos y oclusiones parciales; (2) evaluar arquitecturas CNN modernas que no han sido suficientemente exploradas en este dominio específico; y (3) considerar explícitamente las restricciones computacionales de sistemas embebidos en máquinas SDDR mediante el análisis de tiempos de inferencia.

4. ESTADO DEL ARTE

La clasificación automática de residuos mediante técnicas de visión artificial representa un campo de investigación en rápida evolución que ha experimentado transformaciones significativas en la última década. Este desarrollo ha transitado desde enfoques tradicionales basados en procesamiento manual de características hasta arquitecturas sofisticadas de aprendizaje profundo que aprenden representaciones jerárquicas de manera automática. La convergencia entre la

necesidad ambiental urgente de mejorar sistemas de reciclaje y los avances en inteligencia artificial ha generado un corpus de investigación cada vez más relevante, aunque persisten brechas importantes entre rendimiento en laboratorio y aplicabilidad en entornos operativos reales.

Los primeros trabajos en clasificación automática de residuos emplearon técnicas de visión artificial clásica combinadas con algoritmos de machine learning tradicional. Sakr et al. (2016) [1] implementaron un sistema basado en Support Vector Machines para la clasificación de múltiples tipos de residuos, alcanzando una precisión del 94.8% con SVM (comparado con 83% de una CNN básica en el mismo estudio). Su enfoque requería la extracción manual de características como descriptores de color en espacios HSV, descriptores de textura mediante matrices de co-ocurrencia, y características de forma calculadas a partir de contornos. Aunque establecieron una línea base importante demostrando la viabilidad técnica de automatización, el sistema presentaba limitaciones inherentes: la ingeniería manual de características requería conocimiento experto del dominio, las características diseñadas no generalizaban bien ante variaciones no previstas, y el rendimiento era sensible a cambios en condiciones de captura. Este trabajo, sin embargo, proporcionó insights fundamentales sobre qué propiedades visuales son discriminativas entre tipos de residuos, conocimiento que informaría desarrollos posteriores.

Precisamente estas limitaciones de los métodos tradicionales motivaron la exploración de enfoques alternativos basados en aprendizaje profundo. La transición hacia estos métodos marcó un punto de inflexión en el campo. Awe et al. (2017) [2] en su proyecto de investigación en Stanford demostraron empíricamente la superioridad de redes neuronales convolucionales básicas sobre métodos tradicionales en clasificación de residuos domésticos. Su arquitectura CNN simple, compuesta por apenas tres capas convolucionales seguidas de capas fully-connected, alcanzó 85% de precisión, superando en 7 puntos porcentuales a los mejores métodos tradicionales. Este resultado validó que las CNNs pueden aprender automáticamente representaciones jerárquicas relevantes directamente desde píxeles, eliminando la necesidad de ingeniería manual de características. Sin embargo, el estudio también reveló limitaciones críticas: con un dataset de aproximadamente 500 imágenes, el modelo mostraba signos evidentes de overfitting, y su capacidad de generalización a condiciones no vistas durante entrenamiento era limitada. Este trabajo estableció que, aunque deep learning es prometedor, su éxito depende críticamente de la disponibilidad de datos de entrenamiento suficientes y representativos.

Ante el desafío de escasez de datos en dominios específicos, el concepto de transfer learning emergió como solución fundamental. Malik et al. (2022) [3] aplicaron sistemáticamente transfer learning utilizando EfficientNet-B0 preentrenada en ImageNet para clasificación de residuos sostenibles, evaluando múltiples arquitecturas CNN en un dataset diverso de residuos domésticos. Su enfoque consistió en inicializar la red con pesos aprendidos en el masivo dataset ImageNet

(1.2 millones de imágenes, 1000 clases) y posteriormente realizar fine-tuning en su dataset específico de residuos. Los resultados fueron reveladores: EfficientNet-B0 alcanzó 96.8% de precisión mediante transfer learning, superando significativamente a arquitecturas como VGG16 (92.4%) y ResNet50 (94.2%), demostrando que modelos preentrenados en tareas de reconocimiento visual general capturan características de bajo nivel (bordes, texturas, gradientes) y medio nivel (formas, patrones) que son transferibles y útiles incluso en dominios aparentemente distantes. El transfer learning se consolidó, así como paradigma estándar para aplicaciones de visión artificial con datasets limitados, reduciendo la barrera de entrada para investigación en dominios especializados como clasificación de residuos.

Una vez establecido el transfer learning como paradigma dominante, el foco de investigación se desplazó hacia la identificación de arquitecturas base óptimas para su aplicación. La familia de arquitecturas ResNet, introducida por He et al. (2016) [4], representó un avance arquitectónico fundamental que revolucionó el entrenamiento de redes profundas. Las conexiones residuales o skip connections permiten que la información fluya directamente a través de múltiples capas, mitigando el problema de degradación de gradientes que limitaba el entrenamiento de redes muy profundas. ResNet50, con sus 50 capas organizadas en bloques residuales, logró un equilibrio excepcional entre capacidad representacional y eficiencia computacional. En el benchmark ImageNet, ResNet50 alcanzó un error top-5 de 7.13%, superando significativamente a arquitecturas previas mientras mantenía tiempos de inferencia razonables. Su aplicación específica a clasificación de residuos ha sido explorada extensivamente en literatura posterior, consolidándose como arquitectura baseline de facto para comparativas.

Sin embargo, a pesar de su éxito, ResNet50 no resolvía completamente el desafío de eficiencia computacional, especialmente crítico en aplicaciones con restricciones de recursos. En respuesta a esta necesidad, la familia EfficientNet, propuesta por Tan y Le (2019) [5], introdujo un enfoque sistemático para el escalado de redes convolucionales que desafió el diseño ad-hoc prevalente. Los autores observaron que métodos previos escalaban redes aumentando arbitrariamente una dimensión (profundidad, anchura de canales, o resolución de entrada) mientras mantenían otras constantes. Propusieron en su lugar compound scaling: un método que escala simultánea y balanceadamente las tres dimensiones usando coeficientes determinados mediante búsqueda neural. EfficientNet-B3 alcanzó 81.6% accuracy top-1 en ImageNet usando 12 millones de parámetros y 1.8 mil millones de FLOPs, superando a ResNet50 (76.3% accuracy, 25.5M parámetros, 4.1B FLOPs). Esta eficiencia superior se traduce directamente en ventajas para aplicaciones con restricciones computacionales: menor consumo de memoria, tiempos de inferencia reducidos en aproximadamente 30-40% comparado con ResNet50 para accuracy similar, y menor consumo energético.

Más recientemente, el surgimiento de Vision Transformers como alternativa a las CNNs clásicas planteó interrogantes sobre la vigencia de arquitecturas convolucionales. En este contexto, la arquitectura ConvNeXt, desarrollada por Liu et al. (2022) [6], representa un esfuerzo deliberado de modernizar diseños convolucionales incorporando lecciones aprendidas del éxito de Vision Transformers, pero manteniendo la eficiencia inductiva de convoluciones. Los autores realizaron una serie de modificaciones sistemáticas a ResNet: adopción de estrategia de entrenamiento moderna (AdamW optimizer, data augmentation agresivo), ajustes macro-arquitectónicos (etapas con ratios similares a Swin Transformers), modificaciones a nivel de bloque (depthwise convolutions, kernel 7×7), y micro-diseños inspirados en Transformers (uso de GELU, menos normalizaciones, estructura inversa de bottleneck). El resultado, ConvNeXt-Tiny, alcanzó 82.1% accuracy en ImageNet con 28.6M parámetros, superando a Swin Transformer-Tiny (81.3%, 28M parámetros) mientras mantiene la eficiencia de inferencia de CNNs puras. Estudios recientes de Babu y Mohammed (2024) [7] confirman que ConvNeXt-Tiny ofrece rendimiento superior en tareas de transferencia de aprendizaje con datasets limitados, demostrando que diseños convolucionales modernizados pueden competir con Transformers sin sus requerimientos cuadráticos de memoria respecto a resolución de entrada.

Paralelamente al desarrollo de nuevas arquitecturas, la investigación se ha concentrado en la aplicación específica de estas tecnologías al dominio de reciclaje y gestión de residuos. En este contexto, Ahmed et al. (2023) [8] desarrollaron un sistema comprehensivo de clasificación automática mediante deep learning aplicado a productos reciclables, alcanzando métricas superiores al 90% de precisión. Su contribución metodológica principal fue la implementación de un régimen extensivo de data augmentation específicamente diseñado para simular condiciones reales: variaciones de iluminación mediante ajuste de gamma, rotaciones y perspectivas para simular diferentes ángulos de captura en contenedores, y adición de ruido para simular suciedad superficial. Este trabajo estableció que data augmentation estratégico, diseñado considerando las características específicas del dominio de aplicación, puede mejorar significativamente la robustez del modelo.

Complementando esta línea de investigación metodológica, Mmileng et al. (2024) [9] realizaron una aplicación innovadora de ConvNeXt con transfer learning y data augmentation en detección de parásitos de malaria mediante imágenes microscópicas. Aunque el dominio difiere del reciclaje de residuos, la metodología es directamente transferible: el modelo ConvNeXt Tiny re-ajustado alcanzó 95% de precisión, superando a modelos como Swin Tiny, ResNet18 y ResNet50. Significativamente, la versión modificada ConvNeXt V2 Tiny alcanzó 98% de precisión, demostrando el potencial de arquitecturas ConvNeXt en escenarios con recursos limitados. Los autores enfatizan que estos resultados validan la implementación de sistemas basados en

ConvNeXt en entornos con escasas infraestructuras tecnológicas, contexto análogo a sistemas SDDR en ubicaciones con restricciones de hardware.

En el contexto específico de waste classification con técnicas avanzadas, el trabajo de Olorunnisola et al. (2025) [10] presenta un sistema novedoso de clasificación en tres etapas utilizando una CNN separable en profundidad ligera y paralela (DP-CNN) en conjunto con clasificador ensemble extreme learning machine (En-ELM). Su sistema logró 96% de accuracy en clasificación binaria, 91% en clasificación de nueve clases, y 85.25% en clasificación de 36 clases, con tiempos de testing de apenas 0.00001 segundos. Crucialmente, los autores crearon el dataset comprehensivo TriCascade WasteImage, que combina cuatro datasets preexistentes, proporcionando un recurso valioso para la comunidad. Este trabajo demuestra que arquitecturas ligeras y eficientes pueden alcanzar precisiones competitivas manteniendo viabilidad para deployment en sistemas embebidos.

Más recientemente, estudios específicamente enfocados en residuos domésticos han explorado arquitecturas de vanguardia con mecanismos de atención. Mishra et al. (2025) [11] integraron mecanismos Squeeze and Excitation (SE) y Convolutional Block Attention Module (CBAM) en ResNet-50 para clasificación de residuos en el dataset TrashNet, demostrando mejoras consistentes en precisión mediante la combinación de atención de canal y atención espacial. La integración de estos mecanismos permite que los modelos se enfoquen en regiones discriminativas mientras suprimen características irrelevantes del fondo. Estos avances arquitectónicos demuestran que combinaciones sofisticadas de técnicas pueden impulsar significativamente el rendimiento en clasificación de residuos más allá de arquitecturas estándar.

No obstante, más allá de estas evaluaciones de laboratorio, persiste una problemática crítica que amenaza la viabilidad práctica de estos sistemas. La degradación de rendimiento cuando modelos entrenados en laboratorio se despliegan en entornos operativos reales ha sido abordada críticamente por investigaciones recientes en domain adaptation. Zhang et al. (2023) [12] desarrollaron un enfoque de adaptación de dominio source-free guiado por pre-entrenamiento de visión y visión-lenguaje, demostrando que modelos alcanzando 95% de precisión en datasets capturados en condiciones de laboratorio uniformes experimentaban caídas significativas cuando evaluados con imágenes de entornos reales con iluminación variable, fondos complejos y oclusiones parciales. Los autores propusieron técnicas de co-aprendizaje que aprovechan encoders CLIP preentrenados para mejorar la adaptación zero-shot, logrando reducir la brecha de generalización. Du et al. (2024) [13] extendieron este trabajo específicamente a detección de objetos en escenarios de baja iluminación mediante adaptación de dominio día-noche zero-shot, revisitando la teoría Retinex para diseñar un módulo de aprendizaje de representación de reflectancia que aprende invariancia de iluminación basada en Retinex en imágenes. Estos

trabajos enfatizan la necesidad crítica de diseñar datasets que capturen variabilidad operativa desde el inicio, en lugar de depender exclusivamente de augmentation sintético post-hoc.

En esta línea de mejorar la robustez mediante datasets más representativos, el data augmentation como técnica fundamental para mejorar generalización ha sido objeto de revisiones exhaustivas recientes. Zeng (2024) [14] proporciona una taxonomía comprehensiva de técnicas de augmentation en visión artificial basadas en deep learning, clasificándolas en transformaciones geométricas (rotación, traslación, escalado, shearing, flipping), transformaciones de color (ajuste de brillo, contraste, saturación, hue shifting), transformaciones de espacio (elastic distortions, perspective warping), y técnicas avanzadas (mixup, cutout, random erasing). Su análisis empírico sobre múltiples datasets benchmark demuestra que augmentation puede incrementar accuracy efectiva en 8-15% dependiendo del tamaño inicial del dataset, con mayores ganancias en datasets pequeños. Sin embargo, advierten sobre el riesgo de augmentation excesivo que puede introducir ejemplos semánticamente inconsistentes. Mahmood y Minallah (2023) [15] complementan este análisis con un survey comprehensivo que revisa más de 100 papers publicados en los últimos cinco años sobre data augmentation en clasificación y segmentación, proponiendo nuevas estrategias que incluyen discrete wavelet transform y constant-Q Gabor transform como técnicas de augmentation novedosas.

Más allá de consideraciones puramente técnicas de diseño de modelos, los requisitos operativos de sistemas reales imponen restricciones adicionales que deben considerarse desde las fases iniciales de investigación. Los sistemas de devolución, depósito y retorno (SDDR) específicamente han sido objeto de investigación tecnológica enfocada en estos requisitos. Los datos más recientes de TOMRA (2024) [16] sobre sistemas de depósito en Europa revelan que países con DRS establecidos alcanzan tasas de retorno excepcionales: Alemania supera el 98% de retorno de contenedores de bebidas, Noruega alcanza 92%, y Lituania saltó de una tasa inferior al 34% antes de su sistema de depósito a un impresionante 92% solo dos años después. Irlanda, que lanzó su DRS en febrero de 2024, alcanzó una tasa de retorno del 73% en siete meses. Estos sistemas requieren tiempo de procesamiento inferior a 2 segundos por ítem para mantener throughput adecuado durante horarios pico, precisión mínima de 95% para mantener confianza del usuario, y robustez ante suciedad superficial común en envases usados.

El contexto regulatorio europeo refuerza la urgencia de estos desarrollos tecnológicos. Según el Reglamento de Envases y Residuos de Envases de la UE (PPWR) votado en diciembre de 2024 [17], todos los Estados miembros deben implementar un sistema de depósito para latas y botellas de plástico antes de 2029 para alcanzar los objetivos de recolección separada y contenido reciclado. En España específicamente, la Ley de Economía Circular (7/2022) estableció la expectativa de 70% de recolección separada de botellas de plástico de un solo uso para 2023

mediante sistemas EPR colectivos como Ecoembes. Dado que solo se alcanzó el 41.3%, la ley define la obligación de establecer un sistema SDDR para botellas de plástico de un solo uso en un plazo de 3 años, con fecha límite en noviembre de 2026 [18]. Este contexto regulatorio hace que la investigación en sistemas automáticos de clasificación sea no solo académicamente relevante sino operacionalmente urgente.

Otra consideración técnica relevante en aplicaciones reales es el manejo de clases desbalanceadas, problemática común en datasets de residuos donde ciertos materiales son más frecuentes que otros. Este desafío ha sido tratado por múltiples investigaciones recientes que demuestran que entrenamiento naive con cross-entropy estándar resulta en modelos sesgados. Las estrategias de mitigación incluyen weighted loss functions donde pérdida de cada clase se pondera inversamente a su frecuencia, oversampling sintético de clases minoritarias, y focal loss que down-weight ejemplos fácilmente clasificables. En contexto de reciclaje donde clasificación errónea de cualquier material tiene consecuencias operativas, garantizar precisión uniforme a través de clases es fundamental.

Desde el punto de vista de implementación práctica, la selección de herramientas y frameworks adecuados facilita significativamente la experimentación y desarrollo. El framework PyTorch ha emergido como herramienta dominante en investigación de deep learning por su diseño dinámico y pythonic. Particularmente relevante es TIMM (PyTorch Image Models), librería mantenida por la comunidad que proporciona implementaciones de 400+ arquitecturas de visión con pesos preentrenados en múltiples datasets. TIMM estandariza interfaces entre arquitecturas diversas, facilitando experimentación comparativa sin reimplementación: cargar ResNet50, EfficientNet-B3 o ConvNeXt-Tiny requiere idénticas llamadas de API, simplificando dramáticamente experimentación sistemática.

En cuanto a la evaluación rigurosa del rendimiento de estos sistemas, las métricas de evaluación en clasificación multiclase han sido formalizadas rigurosamente por Sokolova y Lapalme (2009) [19]. Su análisis sistemático de 24 medidas de rendimiento distintas aplicadas a 12 datasets con características variadas (balanceados, desbalanceados, binarios, multiclase) proporciona guías sobre qué métricas son apropiadas en qué contextos. Demuestran matemáticamente que accuracy puede ser severamente engañosa en presencia de desbalance, proponiendo uso sistemático de precision, recall y F1-score calculados per-clase y posteriormente promediados (macro-averaging) o ponderados por frecuencia (weighted-averaging).

Desde una perspectiva de sostenibilidad integral, no solo ambiental sino también computacional, la eficiencia energética de sistemas de IA ha emergido como consideración crítica con implicaciones éticas y prácticas. Strubell et al. (2019) [20] cuantificaron por primera vez la huella de carbono del entrenamiento de modelos deep learning, revelando que entrenar arquitecturas

grandes puede emitir 280 toneladas de CO₂ equivalente. Aunque modelos de clasificación de residuos son típicamente más pequeños, el principio de eficiencia energética permanece relevante. Para sistemas SDDR que pueden procesar millones de ítems anualmente, la eficiencia de inferencia domina el impacto ambiental total.

Finalmente, considerando las restricciones de hardware típicas en aplicaciones reales de reciclaje, la tendencia hacia edge computing en aplicaciones de IA resulta particularmente relevante para sistemas SDDR que requieren procesamiento local en tiempo real sin dependencia de conectividad cloud. Zhou et al. (2019) [21] revisan técnicas de optimización de modelos para dispositivos embebidos: quantization, pruning, knowledge distillation, y neural architecture search específico para hardware target. Demuestran que combinación cuidadosa de técnicas puede reducir latencia de inferencia hasta 10× mientras mantiene accuracy dentro de 1-2% del modelo original.

El panorama del estado del arte revela un campo maduro en fundamentos técnicos de clasificación de residuos mediante deep learning, pero con brechas significativas en aplicabilidad práctica. La mayoría de investigaciones demuestran precisiones impresionantes (90-95%) en condiciones controladas, pero pocos trabajos han validado rendimiento en deployment real durante períodos extendidos. Existe consenso sobre efectividad de transfer learning y data augmentation, pero menos claridad sobre qué arquitecturas específicas son óptimas para el equilibrio precisión-eficiencia requerido en sistemas embebidos SDDR. Las contribuciones metodológicas del presente proyecto se posicionan en estas brechas específicas: primero, el énfasis en captura de dataset en condiciones deliberadamente heterogéneas responde directamente a hallazgos sobre degradación de modelos en deployment; segundo, la inclusión de ConvNeXt-Tiny en comparativa responde a la observación de que arquitecturas CNN modernizadas no han sido suficientemente evaluadas en este dominio específico; tercero, el análisis explícito de trade-offs precisión-eficiencia con mediciones de tiempo de inferencia responde a requisitos operativos identificados pero frecuentemente omitidos en literatura académica.

5. METODOLOGÍA

5.1 Diseño del Dataset

El dataset se construirá mediante captura directa de imágenes de tres clases de residuos reciclables: latas de aluminio, botellas de vidrio y botellas PET. El objetivo es alcanzar entre 900 y 1500 imágenes originales, distribuyendo equitativamente entre 300 y 500 imágenes por clase para garantizar balance y representatividad.

La captura de imágenes se realizará en condiciones deliberadamente heterogéneas para simular la variabilidad de entornos operativos reales en sistemas SDDR. Esto incluye: (a) múltiples condiciones de iluminación (natural diurna, artificial interior, mixta); (b) diversos fondos (uniformes, texturizados, con elementos distractores); (c) variedad de ángulos de captura (frontal, lateral, superior, oblicuo); y (d) diferentes estados de conservación de los envases (nuevo, usado, parcialmente deteriorado, con etiquetas parcialmente desprendidas).

Esta estrategia de captura se justifica porque los trabajos de Zhang et al. (2023) [12] y Du et al. (2024) [13] demuestran que la degradación de precisión en deployment real frecuentemente se atribuye a la discrepancia entre condiciones de entrenamiento y operación. Al incorporar variabilidad desde el origen del dataset, se busca mejorar la robustez del modelo final.

5.2 Data Augmentation

Se aplicará un factor de multiplicación $5\times$ mediante técnicas de data augmentation exclusivamente al conjunto de entrenamiento, generando entre 4500 y 7500 imágenes totales. Las transformaciones incluirán: rotaciones aleatorias ($\pm 30^\circ$), volteos horizontales y verticales, ajustes de brillo ($\pm 20\%$) y contraste ($\pm 15\%$), zoom aleatorio ($0.8-1.2\times$), recortes aleatorios, y adición de ruido gaussiano.

La selección de estas técnicas se fundamenta en el análisis comprehensivo de Zeng (2024) [14] y Mahmood y Minallah (2023) [15], quienes demuestran que transformaciones geométricas y fotométricas moderadas incrementan la capacidad de generalización sin introducir artefactos que alteren semánticamente las clases. La restricción de augmentation al conjunto de entrenamiento (no validación ni test) garantiza que la evaluación se realice sobre datos no transformados, proporcionando una estimación no sesgada del rendimiento real.

5.3 Arquitecturas de Redes Neuronales

5.3.1 Criterios de Selección

La selección de arquitecturas para este estudio comparativo responde a criterios específicos que garantizan representatividad de diferentes paradigmas de diseño CNN y aplicabilidad práctica a sistemas SDDR operativos. Se establecieron tres requisitos fundamentales que toda arquitectura candidata debe cumplir:

Disponibilidad de pesos preentrenados: La arquitectura debe contar con pesos públicamente disponibles entrenados en ImageNet-1K, permitiendo transfer learning efectivo. Este requisito elimina arquitecturas experimentales o propietarias que limitarían la reproducibilidad del estudio.

Balance documentado entre precisión y eficiencia: La arquitectura debe haber demostrado rendimiento competitivo en benchmarks estándar (ImageNet) con requisitos computacionales compatibles con hardware embebido de capacidad media (GPUs de consumo o aceleradores edge). Este criterio excluye tanto arquitecturas excesivamente ligeras con precisión insuficiente como arquitecturas masivas inviables para deployment práctico.

Representatividad de paradigmas de diseño: El conjunto de arquitecturas seleccionadas debe abarcar diferentes filosofías de diseño CNN para permitir conclusiones generalizables sobre qué características arquitectónicas son más beneficiosas en el dominio específico de clasificación de residuos.

Bajo estos criterios, se identificaron tres arquitecturas que representan distintas corrientes de innovación en diseño de CNNs:

ResNet50 representa el paradigma establecido de redes residuales profundas que han dominado visión artificial en la última década. Su inclusión como arquitectura baseline permite: (1) establecer comparación directa con trabajos previos en clasificación de residuos que emplean predominantemente ResNet como referencia, y (2) validar la efectividad del protocolo experimental propuesto mediante replicación de resultados conocidos. ResNet50 representa el estándar industrial contra el cual arquitecturas más recientes deben competir.

EfficientNet-B3 representa el paradigma de diseño eficiente mediante optimización sistemática. A diferencia del escalado ad-hoc de arquitecturas previas, EfficientNet aplica compound scaling que balancea profundidad, anchura y resolución simultáneamente. Su inclusión responde a requisitos prácticos de sistemas SDDR: Tan y Le (2019) [5] demuestran que EfficientNet-B3 supera a ResNet50 en precisión (81.6% vs 76.3% top-1 accuracy en ImageNet) utilizando menos de la mitad de parámetros (12M vs 25.6M) y FLOPs (1.8B vs 4.1B). Esta eficiencia superior se traduce directamente en menores tiempos de inferencia y consumo energético, factores críticos en sistemas que operan continuamente procesando miles de ítems diarios.

ConvNeXt-Tiny representa arquitecturas CNN modernizadas que incorporan innovaciones recientes del campo de Vision Transformers manteniendo la eficiencia inductiva de convoluciones. Su inclusión responde a una brecha específica identificada en el estado del arte: pese a sus ventajas demostradas en benchmarks generales (Liu et al., 2022 [6] reportan 82.1% accuracy superando a Swin Transformer-Tiny), ConvNeXt no ha sido evaluada sistemáticamente en el dominio de clasificación de residuos. Investigaciones recientes como las de Babu y Mohammed (2024) [7] y Mmileng et al. (2024) [9] confirman el potencial de ConvNeXt en escenarios con recursos limitados, logrando precisiones superiores al 95% en tareas de transferencia de aprendizaje.

Arquitecturas descartadas: Se consideraron, pero descartaron arquitecturas más ligeras (MobileNetV2, SqueezeNet) por precisión inferior documentada en trabajos previos. Igualmente se descartaron arquitecturas más pesadas (ResNet101, ResNet152, EfficientNet-B5/B7) por requisitos computacionales incompatibles con hardware embebido típico de máquinas SDDR. Vision Transformers puros (ViT, DeiT) se descartaron por sus requisitos cuadráticos de memoria respecto a resolución de entrada.

5.3.2 Implementación

Se implementarán las tres arquitecturas mediante transfer learning utilizando pesos preentrenados en ImageNet-1K. La implementación empleará la librería TIMM (PyTorch Image Models) que proporciona interfaces estandarizadas, garantizando reproducibilidad.

ResNet50 (He et al., 2016 [4]): Arquitectura de 50 capas con bloques residuales (25.6M parámetros). Las conexiones residuales permiten entrenar redes profundas capturando jerarquías de características apropiadas para discriminar materiales reciclables.

EfficientNet-B3 (Tan y Le, 2019 [5]): Red escalada mediante compound scaling (12M parámetros). El escalado balanceado de profundidad, anchura y resolución proporciona capacidad representacional similar a redes más grandes con significativamente menos parámetros, acelerando inferencia.

ConvNeXt-Tiny (Liu et al., 2022 [6]): CNN modernizada con modificaciones inspiradas en Vision Transformers (28.6M parámetros). Las depthwise convolutions y diseños inspirados en Transformers demuestran que arquitecturas convolucionales modernizadas pueden alcanzar precisión comparable a Transformers manteniendo eficiencia.

Todas las arquitecturas se inicializarán con pesos preentrenados completos y se aplicará fine-tuning de todos los parámetros mediante backpropagation, ya que el dominio target (residuos reciclables) difiere del dominio de preentrenamiento, requiriendo adaptación de características aprendidas.

5.4 Transfer Learning e Implementación

Los tres modelos se inicializarán con pesos preentrenados en ImageNet-1K, aprovechando representaciones visuales generales aprendidas en este dataset masivo (1.2M imágenes, 1000 clases). Los trabajos recientes de Malik et al. (2022) [3] y Mmileng et al. (2024) [9] demostraron que transfer learning reduce drásticamente los requisitos de datos específicos del dominio target, permitiendo convergencia rápida y mejorando generalización.

La adaptación a la tarea específica se realizará mediante: (1) reemplazo de la capa de clasificación final por una capa fully-connected con 3 salidas correspondientes a las clases objetivo; (2) fine-tuning completo de todos los pesos de la red mediante backpropagation, permitiendo que las capas preentrenadas se ajusten al dominio específico de residuos reciclables.

La implementación se desarrollará en PyTorch, framework seleccionado por su flexibilidad y ecosistema maduro para investigación en visión artificial. Se utilizará la librería TIMM (PyTorch Image Models), que proporciona implementaciones optimizadas de arquitecturas modernas con acceso directo a múltiples versiones de pesos preentrenados, facilitando experimentación reproducible.

5.5 Protocolo de Entrenamiento

El dataset se dividirá siguiendo la práctica estándar: 70% entrenamiento, 15% validación, 15% test. El conjunto de entrenamiento se someterá a data augmentation ($\times 5$), mientras validación y test permanecerán sin modificar. Esta partición garantiza evaluación no sesgada en el conjunto test, que simula datos nunca vistos durante el desarrollo.

El entrenamiento empleará optimización Adam con learning rate inicial de $1e-4$, que se reducirá mediante scheduling dinámico cuando la pérdida en validación se estanque. Se utilizará cross-entropy loss como función objetivo, apropiada para clasificación multiclase. El entrenamiento continuará hasta convergencia o un máximo de 100 épocas, aplicando early stopping si la métrica de validación no mejora durante 15 épocas consecutivas.

5.6 Evaluación Comparativa

La evaluación considerará dos dimensiones fundamentales: precisión de clasificación y eficiencia computacional.

Métricas de Precisión: Se calcularán Accuracy (proporción de predicciones correctas), Precision (proporción de predicciones positivas correctas por clase), Recall (proporción de instancias positivas correctamente identificadas), y F1-Score (media armónica de Precision y Recall). Sokolova y Lapalme (2009) [19] argumentan que F1-Score proporciona una medida balanceada particularmente relevante cuando existe ligero desbalance entre clases o cuando errores de falsos positivos y falsos negativos tienen costos similares.

Matrices de Confusión: Se generarán para cada modelo, permitiendo identificar patrones específicos de confusión entre clases. Por ejemplo, si el sistema confunde frecuentemente botellas PET con vidrio, esto indicaría necesidad de augmentation específico o ingeniería de características adicional para esas clases.

Tiempos de Inferencia: Se medirán en hardware representativo de sistemas embebidos potenciales (GPU NVIDIA de gama media), reportando tiempo promedio de procesamiento por imagen. Los datos recientes de TOMRA (2024) [16] establecen que sistemas SDDR operativos requieren tiempos de procesamiento inferiores a 2 segundos por ítem para mantener throughput adecuado en horarios pico.

Criterio de Selección: El modelo óptimo se determinará mediante análisis multicriterio considerando: (1) F1-Score ≥ 0.90 como requisito mínimo de precisión; (2) tiempo de inferencia < 1 segundo como requisito deseable para aplicabilidad práctica; (3) análisis de matriz de confusión para identificar errores sistemáticos.

6. PLANIFICACIÓN

6.1 Cronograma (12 semanas)

Semanas 1-3: Diseño y ejecución del protocolo de captura de imágenes. Adquisición de 900-1500 fotografías siguiendo las especificaciones de variabilidad definidas. Etiquetado manual y organización inicial del dataset.

Semanas 4-5: Implementación del pipeline de preprocesamiento. Desarrollo de scripts de data augmentation. Partición del dataset en conjuntos de entrenamiento, validación y test. Verificación de balance de clases y representatividad.

Semanas 6-8: Implementación de las tres arquitecturas CNN en PyTorch con TIMM. Configuración de protocolos de entrenamiento. Ejecución de experimentos de entrenamiento para ResNet50, EfficientNet-B3 y ConvNeXt-Tiny. Monitoreo de convergencia y ajuste de hiperparámetros si es necesario.

Semanas 9-10: Evaluación exhaustiva de los modelos entrenados en conjunto test. Cálculo de métricas de precisión y eficiencia. Generación de matrices de confusión y análisis de errores. Comparativa sistemática de resultados.

Semanas 11-12: Redacción de documentación completa del proyecto. Preparación de visualizaciones y tablas comparativas. Elaboración de memoria final y materiales para defensa oral.

6.2 Recursos Necesarios

Hardware: Cámara digital con resolución mínima de 12MP para captura de imágenes de alta calidad. Ordenador equipado con GPU NVIDIA (mínimo 8GB VRAM) para entrenamiento eficiente de redes profundas. El entrenamiento de arquitecturas como EfficientNet-B3 en datasets de 4500-7500 imágenes requiere aceleración GPU para completarse en plazos razonables (días en lugar de semanas).

Software: Python 3.8+, PyTorch 2.0+, librería TIMM, librerías complementarias de visión artificial (OpenCV, Pillow, albumentations para augmentation), herramientas de visualización (matplotlib, seaborn), Jupyter notebooks para experimentación interactiva.

Materiales: Recolección de ejemplares representativos de las tres clases (latas de aluminio, botellas de vidrio, botellas PET) en diferentes estados de conservación. Acceso a espacios con variedad de condiciones de iluminación para captura fotográfica.

7. EVALUACIÓN Y MÉTRICAS

La evaluación del sistema se estructurará en tres niveles complementarios:

7.1 Métricas Cuantitativas

Accuracy (Exactitud): Proporción total de clasificaciones correctas sobre el total de predicciones. Proporciona una visión general del rendimiento pero puede ser engañosa en presencia de desbalance de clases. Se reportará para cada modelo como métrica primaria de comparación.

Precision (Precisión por clase): Para cada clase, proporción de predicciones positivas que son realmente correctas. Crítica en contexto SDDR porque falsos positivos generan contaminación cruzada de flujos de reciclaje.

Recall (Sensibilidad): Para cada clase, proporción de instancias reales que son correctamente identificadas. Mide la capacidad del sistema de detectar todos los ejemplares de una clase. Recall bajo implica rechazo de residuos reciclables válidos, reduciendo eficiencia del sistema SDDR.

F1-Score: Media armónica de Precision y Recall, proporcionando una métrica balanceada especialmente relevante cuando ambos tipos de error tienen costos similares. Como demuestran Sokolova y Lapalme (2009) [19], $F1\text{-Score} \geq 0.90$ en clasificación multiclase indica rendimiento robusto apropiado para deployment.

7.2 Análisis Cualitativo

Matrices de Confusión: Visualización detallada de patrones de error, identificando qué clases se confunden más frecuentemente. Esto permite: (a) identificar clases problemáticas que requieren más datos o augmentation específico, (b) entender si errores son aleatorios o sistemáticos, (c) informar decisiones de diseño para iteraciones futuras.

Análisis de Casos de Error: Inspección manual de imágenes mal clasificadas para identificar causas raíz (oclusiones, iluminación extrema, daño severo del envase, etc.). Este análisis cualitativo complementa métricas cuantitativas proporcionando insights accionables.

7.3 Métricas de Eficiencia

Tiempo de Inferencia: Tiempo promedio de procesamiento por imagen medido en hardware representativo. Se reportará media y desviación estándar sobre 1000 inferencias. Este criterio es determinante para viabilidad en sistemas SDDR operativos donde el throughput es crítico.

Tamaño del Modelo: Número de parámetros y memoria requerida en deployment. Relevante para evaluación de viabilidad en sistemas embebidos con recursos limitados.

7.4 Criterio de Decisión

La selección del modelo óptimo seguirá este protocolo jerárquico:

Requisito mínimo: $F1\text{-Score} \geq 0.90$ en las tres clases. Modelos que no alcancen este umbral se consideran no aptos para deployment.

Criterio de eficiencia: Entre modelos que cumplan el requisito mínimo, se priorizará aquel con menor tiempo de inferencia, siempre que la diferencia en F1-Score no supere 2 puntos porcentuales.

Análisis de errores: Si dos modelos son equivalentes en precisión y eficiencia, se preferirá aquel cuya matriz de confusión muestre errores más uniformemente distribuidos en lugar de confusiones sistemáticas entre clases específicas.

8. RESULTADOS ESPERADOS

Al finalizar el proyecto se espera obtener:

Sistema de Clasificación Funcional: Un modelo de clasificación automática de residuos reciclables que supere el 90% de F1-Score en las tres clases objetivo, validado en condiciones que simulan operación real en sistemas SDDR.

Dataset Etiquetado Original: Un conjunto de 900-1500 imágenes reales de residuos reciclables capturadas en condiciones controladamente heterogéneas, disponible para publicación y uso en futuras investigaciones. Este dataset contribuirá a la comunidad académica proporcionando datos representativos de condiciones operativas reales, una brecha identificada en el estado del arte.

Análisis Comparativo Riguroso: Evaluación sistemática de tres arquitecturas CNN modernas (ResNet50, EfficientNet-B3, ConvNeXt-Tiny) en el dominio específico de clasificación de residuos, incluyendo análisis de trade-offs precisión-eficiencia. Los resultados proporcionarán evidencia empírica sobre qué arquitecturas son más apropiadas para aplicaciones SDDR considerando restricciones de tiempo real.

Documentación Metodológica Completa: Descripción detallada y reproducible de todo el pipeline (captura de datos, preprocesamiento, augmentation, entrenamiento, evaluación), facilitando replicación y extensión por otros investigadores. Se incluirán protocolos específicos de captura de imágenes y configuraciones exactas de hiperparámetros.

Recomendaciones para Deployment: Basadas en el análisis comparativo, se proporcionarán recomendaciones específicas sobre qué arquitectura implementar en sistemas SDDR reales considerando restricciones de hardware embebido, requisitos de throughput y tolerancia a errores.

9. ORIGINALIDAD Y APORTACIÓN

Este proyecto realiza aportaciones específicas en tres dimensiones:

Aportación Metodológica: Desarrollo de un protocolo de captura de imágenes que deliberadamente incorpora variabilidad representativa de condiciones operativas reales. Mientras trabajos previos utilizan imágenes en condiciones controladas y posteriormente aplican augmentation sintético, este proyecto captura variabilidad real desde el origen, potencialmente mejorando la robustez del modelo final, siguiendo las recomendaciones de Zhang et al. (2023) [12] y Du et al. (2024) [13] sobre domain adaptation.

Aportación Empírica: Comparativa rigurosa de arquitecturas CNN modernas (particularmente ConvNeXt-Tiny) en clasificación de residuos, dominio donde estas arquitecturas no han sido suficientemente evaluadas. Los trabajos previos se centran predominantemente en ResNet y variantes, dejando sin explorar arquitecturas más recientes que, según Babu y Mohammed (2024) [7] y Mmileng et al. (2024) [9], podrían ofrecer mejores trade-offs.

Aportación Aplicada: Enfoque explícito hacia viabilidad de deployment en sistemas SDDR mediante análisis sistemático de tiempos de inferencia y requisitos computacionales. El contexto regulatorio europeo actual, con la obligación de España de implementar SDDR antes de noviembre de 2026 según la Ley 7/2022 [18], hace que esta investigación sea operativamente urgente y aplicada.

Contribución de Datos: Generación de un dataset etiquetado de residuos reciclables capturado en condiciones deliberadamente heterogéneas, que se pondrá a disposición de la comunidad académica. Los datasets públicos existentes, como el TriCascade WasteImage de Olorunnisola et al. (2025) [10], demuestran el valor de contribuciones de datos comprehensivas para avanzar el campo.

10. LIMITACIONES Y RIESGOS

10.1 Identificación de Limitaciones

Tamaño del Dataset: Con 900-1500 imágenes originales (4500-7500 post-augmentation), el dataset es modesto comparado con benchmarks estándar de visión artificial. Aunque transfer learning mitiga parcialmente esta limitación, existe riesgo de que el modelo no capture completamente la variabilidad de residuos en condiciones reales extremas.

Condiciones de Captura: Pese a buscar heterogeneidad, la captura individual puede no replicar perfectamente todas las condiciones de sistemas SDDR operativos (suciedad extrema, deformaciones severas, oclusiones parciales por otros objetos). Esto podría limitar la generalización directa a deployment sin fine-tuning adicional.

Limitación de Clases: El enfoque en tres clases específicas (PET, vidrio, aluminio) no cubre la totalidad de residuos reciclables encontrados en sistemas SDDR reales (cartón, otros plásticos, metales diversos). La extensión a más clases requeriría escalado proporcional del dataset.

Recursos Computacionales: El entrenamiento de tres arquitecturas modernas requiere acceso a GPU con capacidad adecuada. Fallos de hardware o indisponibilidad temporal podrían retrasar el cronograma.

Variabilidad Temporal: La captura se realizará en un período limitado (3 semanas), potencialmente sin cubrir variaciones estacionales (por ejemplo, cambios de iluminación natural entre estaciones) que podrían afectar a sistemas desplegados durante todo el año.

10.2 Estrategias de Mitigación

Maximización de Variabilidad en Captura: Protocolo estructurado que asegure cobertura sistemática de condiciones de iluminación (natural amanecer/mediodía/atardecer, artificial fría/cálida, mixta), fondos (5+ tipos diferentes), ángulos (mínimo 8 perspectivas por objeto), y estados (nuevo/usado/deteriorado). Uso de checklist para verificar representatividad.

Data Augmentation Estratégico: Aplicación intensiva de transformaciones que simulen condiciones no capturadas naturalmente siguiendo las recomendaciones de Zeng (2024) [14] y Mahmood y Minallah (2023) [15]: degradación de nitidez, simulación de suciedad mediante overlays, variación extrema de brillo/contraste. Aunque sintético, esto complementa variabilidad real del dataset original.

Validación Cruzada Rigurosa: Implementación de k-fold cross-validation ($k=5$) además de partición test fija, proporcionando estimación más robusta de rendimiento esperado y reduciendo riesgo de sobre-optimización al conjunto test específico.

Planificación de Contingencia Computacional: Identificación previa de recursos GPU alternativos (cloud computing, laboratorios universitarios adicionales) en caso de fallos de hardware. **Priorización de experimentos:** comenzar con arquitectura baseline (ResNet50) para garantizar resultados mínimos, luego proceder con arquitecturas adicionales.

Monitoreo de Progreso: Evaluaciones semanales de avance contra cronograma con hitos verificables. Identificación temprana de retrasos permite ajustes sin comprometer objetivos fundamentales.

Documentación de Limitaciones: Registro exhaustivo de decisiones de diseño y condiciones de captura, permitiendo que usuarios futuros del sistema comprendan su dominio de validez y necesidad de fine-tuning si deployment se realiza en condiciones significativamente diferentes.

11. CONSIDERACIONES ÉTICAS Y SOSTENIBILIDAD

11.1 Contribución a la Sostenibilidad

El proyecto se alinea directamente con los Objetivos de Desarrollo Sostenible (ODS) de Naciones Unidas, específicamente:

ODS 12 (Producción y Consumo Responsables): La automatización de clasificación de residuos incrementa la eficiencia de sistemas de reciclaje, reduciendo contaminación cruzada entre materiales y aumentando las tasas de reciclaje efectivo. La mejora de precisión de 75-80%

(sistemas manuales típicos) a >90% (sistema propuesto) podría incrementar el volumen de material efectivamente reciclado en 10-15%. Los datos de TOMRA (2024) [16] demuestran que países con DRS establecidos alcanzan tasas de retorno excepcionales superiores al 90%.

ODS 13 (Acción por el Clima): El reciclaje de aluminio reduce emisiones de CO₂ en un 95% comparado con producción primaria; el reciclaje de PET reduce emisiones en 50-70%. Al mejorar la eficiencia de clasificación, el sistema contribuye indirectamente a reducción de huella de carbono en procesos industriales.

Eficiencia Energética del Sistema: La selección de arquitecturas considerando explícitamente tiempos de inferencia no solo responde a requisitos operativos sino también a sostenibilidad. Strubell et al. (2019) [20] demuestran que modelos más eficientes reducen consumo energético en deployment a largo plazo. Un sistema SDDR procesando 10,000 ítems diarios durante 10 años con un modelo 30% más eficiente puede resultar en ahorros energéticos significativos acumulados.

11.2 Privacidad y Consideraciones Legales

Protección de Datos: La captura de imágenes se realizará exclusivamente de objetos (residuos), sin personas, espacios privados o información identificable. Esto elimina preocupaciones relacionadas con GDPR (Reglamento General de Protección de Datos) y legislación de privacidad.

Consentimiento de Captura: Las imágenes se adquirirán en espacios controlados (domésticos, laboratorio) con consentimiento explícito de participantes. No se realizarán capturas en espacios públicos o privados sin autorización.

Uso de Datos: El dataset generado no contendrá metadatos que permitan identificación de origen, fecha específica o ubicación precisa de captura. Su publicación como recurso académico no presenta riesgos de privacidad.

Transparencia Algorítmica: En el contexto de sistemas SDDR donde decisiones de clasificación tienen implicaciones económicas (devolución de depósitos), es importante que el sistema sea auditable. El proyecto documentará exhaustivamente el pipeline de decisión, permitiendo trazabilidad de clasificaciones.

11.3 Consideraciones de Equidad

Accesibilidad Tecnológica: El enfoque en arquitecturas eficientes y documentación exhaustiva facilita que la metodología sea adoptable incluso por organizaciones con recursos computacionales limitados, contribuyendo a democratización de tecnologías de reciclaje

inteligente. Los trabajos de Mmileng et al. (2024) [9] y Olorunnisola et al. (2025) [10] demuestran que arquitecturas ligeras pueden lograr precisiones competitivas en entornos con escasas infraestructuras tecnológicas.

Aplicabilidad Global: Aunque el proyecto se desarrolla en contexto específico, la metodología es transferible a diferentes regiones y tipos de residuos, potenciando su impacto. La disponibilidad del dataset y código facilitará adaptación a contextos diversos.

12. REFERENCIAS

- [1] Sakr, G. E., Mokbel, M., Darwich, A., Khneisser, M. N., & Hadi, A. (2016). Comparing deep learning and support vector machines for autonomous waste sorting. In 2016 IEEE International Multidisciplinary Conference on Engineering Technology (IMCET) (pp. 207-212). IEEE. <https://doi.org/10.1109/IMCET.2016.7777444>
- [2] Awe, O., Mengistu, R., & Sreedhar, V. (2017). Smart trash net: Waste localization and classification. CS229 Project Report, Stanford University.
- [3] Malik, M., Sharma, S., Uddin, M., Chen, C. L., Wu, C. M., & Soni, P. (2022). Waste classification for sustainable development using image recognition with deep learning neural network models. *Sustainability*, 14(12), 7222. <https://doi.org/10.3390/su14127222>
- [4] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).
- [5] Tan, M., & Le, Q. (2019). Efficientnet: Rethinking model scaling for convolutional neural networks. In *International conference on machine learning* (pp. 6105-6114). PMLR.
- [6] Liu, Z., Mao, H., Wu, C. Y., Feichtenhofer, C., Darrell, T., & Xie, S. (2022). A convnet for the 2020s. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 11976-11986).
- [7] Babu, K. S., & Mohammed, A. A. (2024). ConvNeXt and Swin Transformer for Improved Transfer Learning with Limited Data. *Journal of Soft Computing and Data Mining*, 5(1), 24-34.
- [8] Ahmed, I., Ahmad, M., Rodrigues, J. J., & Jeon, G. (2023). Deep learning-based automatic waste classification. *Sustainability*, 15(4), 3685.
- [9] Mmileng, S. B., Moyo, S., & Ouahada, K. (2024). ConvNeXt with Transfer Learning and Data Augmentation for Malaria Parasite Detection. *Applied Sciences*, 14(6), 2432.

[10] Olorunnisola, F. E., Adegun, A. A., Mirkes, E. M., Adetiba, E., & Ekong, V. E. (2025). A Novel Three-stage Approach for Efficient Waste Classification: Integrating Depthwise Parallel Convolutional Neural Network and Ensemble Extreme Learning Machine. *Expert Systems with Applications*, 262, 125557.

[11] Mishra, A., Kumar, V., Singh, R., & Sharma, S. (2025). Optimizing Waste Management with Squeeze-and-Excitation and Convolutional Block Attention Integration in ResNet-Based Deep Learning Frameworks. *Journal of Artificial Intelligence and Technology*, 5(2), 123-135.

<https://doi.org/10.37965/jait.2025.0709>

[12] Zhang, Y., Wei, X. S., Zhou, J., & Wu, J. (2023). Source-free domain adaptation guided by vision and vision-language pre-training. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 46(4), 2164-2178.

[13] Du, J., Xu, L., Wang, H., & Dong, W. (2024). Zero-shot day-night domain adaptation with a physics prior. In *Proceedings of the IEEE/CVF International Conference on Computer Vision* (pp. 21533-21543).

[14] Zeng, H. (2024). Data Augmentation Methods in Deep Learning for Image Classification: A Comprehensive Survey. *Journal of Imaging Science and Technology*, 68(2), 020501.

[15] Mahmood, A., & Minallah, N. (2023). A Comprehensive Survey on Data Augmentation Techniques for Classification and Segmentation. *IEEE Access*, 11, 89887-89911.

[16] TOMRA. (2024). Deposit Return Systems in Europe: Performance Data 2023-2024. TOMRA Collection Solutions. Retrieved December 10, 2024, from <https://www.tomra.com/en/collection/reverse-vending/insights/reports>

[17] European Commission. (2024). Packaging and Packaging Waste Regulation (PPWR). Official Journal of the European Union. Retrieved December 2024.

[18] Gobierno de España. (2022). Ley 7/2022, de 8 de abril, de residuos y suelos contaminados para una economía circular. *Boletín Oficial del Estado*, núm. 85.

<https://www.boe.es/eli/es/l/2022/04/08/7/con>

[19] Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427-437.

[20] Strubell, E., Ganesh, A., & McCallum, A. (2019). Energy and policy considerations for deep learning in NLP. *arXiv preprint arXiv:1906.02243*.

[21] Zhou, Z., Chen, X., Li, E., Zeng, L., Luo, K., & Zhang, J. (2019). Edge intelligence: Paving the last mile of artificial intelligence with edge computing. *Proceedings of the IEEE*, 107(8), 1738-1762.